

**ANALISIS POLA PENJUALAN DAN PENGIRIMAN PADA DATASET
E-COMMERCE INDONESIA PERIODE DESEMBER 2023–NOVEMBER 2025**

Dosen Pengampu : Dr. Marischa Elveny, S.TI., M.Kom..



DISUSUN OLEH:

Ahmad Arif Fatahillah	241402036
Rahma Sarita Nasution	241402043
Agnes Olivia Ketaren	241402066
Richard Lim	241402073
Bryan Sullivan Nauli	241402108

**FAKULTAS ILMU KOMPUTER DAN TEKNOLOGI INFORMASI UNIVERSITAS
SUMATERA UTARA**

2026

BAB I PENDAHULUAN DAN PERUMUSAN MASALAH

1.1 Latar Belakang

Perkembangan perdagangan elektronik atau *e-commerce* telah menghasilkan data transaksi dalam jumlah besar yang dapat dimanfaatkan untuk memahami pola penjualan, perilaku transaksi, serta proses pengiriman barang. Data tersebut tidak hanya mencatat jumlah transaksi, tetapi juga dapat memuat informasi mengenai waktu pemesanan, kategori produk, lokasi pelanggan, nilai pembayaran, status pesanan, dan informasi pengiriman. Apabila dianalisis dengan tepat, data transaksi dapat memberikan informasi yang berguna dalam mendukung pengambilan keputusan.

Pada proyek ini digunakan dataset Indonesia E-Commerce Sales and Shipping 2023–2025 yang berisi data penjualan dan pengiriman e-commerce di Indonesia. Data yang dianalisis berasal dari berkas mentah (*RAW_PUBLIC*) dan bukan langsung menggunakan berkas hasil pembersihan yang telah disediakan oleh penerbit dataset. Oleh karena itu, sebelum dilakukan analisis, data terlebih dahulu melalui proses pembersihan dan validasi agar hasil analisis tidak dipengaruhi oleh masalah kualitas data.

Periode yang digunakan dalam analisis adalah Desember 2023 sampai November 2025. Data selama periode tersebut memungkinkan analisis dilakukan secara temporal untuk melihat perubahan jumlah transaksi maupun nilai pembayaran dari bulan ke bulan. Selain dimensi waktu, informasi kategori produk dan wilayah juga memungkinkan identifikasi produk yang banyak muncul dalam transaksi serta wilayah yang memberikan kontribusi pembayaran terbesar.

Dataset memiliki karakteristik yang perlu diperhatikan sebelum melakukan analisis. Beberapa informasi transaksi muncul berulang pada setiap item dalam satu pesanan sehingga perhitungan pada tingkat pesanan tidak dapat dilakukan dengan menjumlahkan seluruh baris secara langsung. Oleh sebab itu, pada tahap pembersihan dibentuk dua tingkat data, yaitu data item dan data pesanan. Data item digunakan untuk analisis yang berkaitan dengan produk, sedangkan data pesanan digunakan untuk menghitung jumlah pesanan dan nilai pembayaran agar tidak terjadi penghitungan ganda.

Selain itu, beberapa atribut memiliki keterbatasan interpretasi. Kolom seperti diskon dan beberapa komponen ongkos kirim belum memiliki satuan rupiah yang dapat diverifikasi

sehingga tidak digunakan sebagai indikator keuangan utama. Sebaliknya, nilai total pembayaran yang telah dibersihkan digunakan untuk menganalisis transaksi, terutama pada pesanan dengan status selesai. Pemisahan tersebut dilakukan agar hasil analisis tetap sesuai dengan informasi yang dapat dipertanggungjawabkan dari dataset.

Berdasarkan kondisi tersebut, proyek ini mengambil judul “Analisis Pola Penjualan dan Pengiriman pada Dataset E-Commerce Indonesia Periode Desember 2023–November 2025”. Analisis dilakukan melalui tahapan identifikasi masalah, pengumpulan dan pemahaman data, pembersihan data, analisis karakteristik *big data* menggunakan konsep 5V, *Exploratory Data Analysis* (EDA), visualisasi melalui dashboard, serta penyusunan insight berdasarkan hasil analisis.

Melalui proses tersebut, diharapkan data transaksi yang awalnya berupa kumpulan data mentah dapat diubah menjadi informasi yang lebih mudah dipahami mengenai perkembangan transaksi, kategori produk, wilayah pelanggan, serta status penyelesaian pesanan.

1.2 Pertanyaan Analitik

Berdasarkan latar belakang tersebut, pertanyaan analitik yang digunakan dalam proyek ini adalah sebagai berikut:

1. Bagaimana perkembangan jumlah pesanan e-commerce selama periode Desember 2023 sampai November 2025, khususnya pesanan yang telah selesai?
2. Bagaimana tren nilai pembayaran pada pesanan yang telah selesai dari bulan ke bulan dan pada periode mana nilai pembayaran tertinggi terjadi?
3. Kategori produk apa yang paling sering muncul dalam pesanan yang berstatus selesai?
4. Provinsi mana yang memberikan kontribusi nilai pembayaran terbesar pada pesanan yang telah selesai?
5. Bagaimana distribusi status pesanan dalam dataset, termasuk pesanan yang selesai dan dibatalkan, serta apa yang dapat diketahui dari pola tersebut?

1.3 Tujuan Analisis

Berdasarkan pertanyaan analitik yang telah dirumuskan, tujuan proyek ini adalah menganalisis pola penjualan dan pengiriman pada dataset e-commerce Indonesia sehingga dapat diperoleh gambaran mengenai perkembangan transaksi selama periode pengamatan.

Secara lebih khusus, analisis bertujuan untuk mengetahui tren jumlah pesanan dan nilai pembayaran, mengidentifikasi kategori produk yang paling sering muncul dalam transaksi selesai, mengetahui wilayah dengan kontribusi pembayaran terbesar, menganalisis distribusi status pesanan, serta menghasilkan insight yang dapat digunakan sebagai dasar untuk memahami pola aktivitas e-commerce dalam dataset.

Selain menghasilkan insight, proyek ini juga bertujuan menerapkan proses pengolahan *big data* secara sistematis mulai dari pembersihan dan validasi data, analisis karakteristik data menggunakan konsep 5V, eksplorasi data, hingga penyajian hasil melalui visualisasi dan dashboard.

BAB II DESKRIPSI DATASET DAN ANALISIS 5V

2.1 Deskripsi Dataset

Dataset yang digunakan dalam proyek ini adalah Indonesia E-Commerce Sales and Shipping 2023–2025 yang diperoleh dari Kaggle. Data yang digunakan berasal dari kumpulan berkas mentah pada folder RAW_PUBLIC, bukan dari file `all_months_clean.csv` yang telah dibersihkan sebelumnya. Dengan menggunakan data mentah, proses pembersihan, validasi, dan pembentukan struktur data dilakukan sendiri sebagai bagian dari tahapan analisis.

Dataset berisi informasi mengenai aktivitas transaksi e-commerce, seperti identitas pesanan, waktu transaksi, kategori produk, wilayah pelanggan, status pesanan, nilai pembayaran, berat pesanan, diskon, ongkos kirim, serta informasi retur. Informasi tersebut memungkinkan analisis dilakukan dari beberapa sudut pandang, yaitu waktu, produk, wilayah, nilai transaksi, dan status pemenuhan pesanan.

Periode data yang digunakan dalam analisis adalah Desember 2023 sampai November 2025. Penentuan periode analisis terutama menggunakan bulan dari waktu pesanan. Apabila informasi waktu pesanan tidak tersedia secara lengkap, bulan yang terdapat pada nama file digunakan sebagai periode analisis sehingga data tetap dapat dikelompokkan secara bulanan.

Salah satu karakteristik penting dataset adalah adanya informasi tingkat pesanan yang berulang pada beberapa baris karena satu pesanan dapat terdiri atas lebih dari satu item. Oleh sebab itu, setelah proses pembersihan, data dibedakan menjadi dua bentuk utama, yaitu:

1. Data item, yaitu data yang mempertahankan satu baris sumber atau item. Data ini digunakan untuk analisis yang berkaitan dengan kategori produk dan pemeriksaan kualitas data pada tingkat baris.
2. Data pesanan, yaitu data yang telah diringkas menjadi satu baris untuk setiap `order_id`. Data ini digunakan untuk menghitung jumlah pesanan, total pembayaran, status pesanan, berat pesanan, wilayah, serta analisis transaksi lainnya.

Pemisahan tersebut dilakukan untuk menghindari terjadinya penghitungan ganda. Sebagai contoh, apabila nilai total pembayaran terdapat pada setiap baris item dalam pesanan yang sama, menjumlahkan seluruh baris secara langsung akan menyebabkan nilai pembayaran satu pesanan dihitung lebih dari satu kali. Oleh karena itu, nilai total pembayaran digunakan pada tingkat pesanan.

Beberapa atribut penting yang digunakan dalam proses analisis antara lain `order_id`, waktu pesanan, periode analisis, kategori produk, provinsi, status pesanan, total pembayaran, total berat, serta informasi terkait retur dan indikator kualitas data.

Selain data utama, proses cleaning juga menghasilkan beberapa file pendukung, yaitu `laporan_kualitas.csv` untuk mencatat hasil pemeriksaan kualitas data dan `batas_outlier.csv` untuk menyimpan batas serta jumlah data yang terindikasi sebagai outlier.

2.2 Analisis Karakteristik 5V Big Data

Untuk memahami karakteristik dataset, dilakukan analisis menggunakan konsep 5V Big Data, yaitu *Volume*, *Velocity*, *Variety*, *Veracity*, dan *Value*. Kelima aspek tersebut digunakan untuk melihat karakteristik data tidak hanya dari jumlahnya, tetapi juga dari kecepatan pertumbuhan, keragaman, kualitas, dan manfaat yang dapat diperoleh dari proses analisis.

2.2.1 Volume

Volume menggambarkan ukuran atau jumlah data yang harus dikelola dalam proses analisis. Pada dataset ini, data berasal dari banyak transaksi e-commerce yang dikumpulkan selama periode hampir dua tahun. Satu pesanan dapat terdiri atas lebih dari satu item sehingga jumlah baris data dapat lebih besar daripada

jumlah pesanan sebenarnya. Kondisi ini menyebabkan data perlu diproses pada dua tingkat, yaitu tingkat item dan tingkat pesanan.

Banyaknya transaksi dan variabel seperti identitas pesanan, waktu, kategori, lokasi, pembayaran, berat, status, diskon, ongkir, dan retur membuat dataset memiliki volume yang cukup besar untuk dianalisis secara manual. Oleh karena itu, pengolahan dilakukan menggunakan Python dan Pandas agar proses penggabungan, pembersihan, transformasi, dan analisis dapat dilakukan secara lebih efisien.

Volume data juga membuat proses agregasi menjadi penting. Data tidak hanya dibaca sebagai kumpulan baris, tetapi diringkas berdasarkan `order_id`, bulan, kategori produk, provinsi, dan status pesanan agar pola utama lebih mudah diamati.

2.2.2 Velocity

Velocity berkaitan dengan kecepatan data dihasilkan, diperbarui, atau bertambah seiring waktu. Dataset merepresentasikan aktivitas transaksi e-commerce yang berlangsung secara berkelanjutan. Transaksi baru dapat terjadi setiap saat dan menghasilkan data baru mengenai pesanan, pembayaran, pengiriman, hingga perubahan status pesanan.

Pada dataset yang digunakan dalam proyek ini, data tersedia dalam bentuk kumpulan historis dari Desember 2023 sampai November 2025. Meskipun analisis tidak dilakukan secara *real-time*, struktur data menunjukkan karakteristik velocity karena transaksi bertambah mengikuti waktu dan dapat dianalisis secara bulanan.

Untuk menangani karakteristik tersebut, data dibentuk menjadi variabel `periode_analisis` agar seluruh transaksi dapat dikelompokkan berdasarkan bulan. Periode terutama diambil dari waktu pesanan, sedangkan pada data yang tidak memiliki informasi waktu lengkap, periode dapat diperoleh dari bulan pada nama file. Pendekatan ini memungkinkan analisis tren dilakukan secara konsisten sepanjang periode pengamatan.

2.2.3 Variety

Variety menunjukkan keragaman jenis, format, dan karakteristik data yang tersedia. Dataset memiliki berbagai jenis variabel. Beberapa variabel berbentuk kategorikal, seperti kategori produk, provinsi, dan status pesanan. Variabel lain berbentuk numerik, seperti total pembayaran dan total berat. Selain itu, terdapat informasi waktu transaksi serta atribut diskon, ongkir, dan retur.

Keragaman tersebut menyebabkan setiap jenis data memerlukan metode pemrosesan yang berbeda. Data waktu perlu dikonversi ke format tanggal atau periode, data pembayaran perlu dibersihkan dari format teks rupiah, sedangkan data kategorikal perlu distandarkan sebelum dilakukan pengelompokan.

Dataset juga memiliki keragaman pada tingkat observasi. Sebagian informasi menggambarkan item produk, sedangkan sebagian lainnya menggambarkan keseluruhan pesanan. Perbedaan tersebut menjadi alasan utama pembentukan tabel data item dan tabel data pesanan.

Dengan demikian, aspek variety pada dataset tidak hanya terlihat dari banyaknya kolom, tetapi juga dari perbedaan tipe data dan tingkat informasi yang direpresentasikan oleh setiap atribut.

2.2.4 Veracity

Veracity berkaitan dengan tingkat kualitas, konsistensi, kelengkapan, dan keandalan data. Aspek ini menjadi salah satu bagian penting dalam dataset karena data mentah masih memiliki beberapa kondisi yang perlu diperiksa sebelum digunakan untuk analisis. Salah satunya adalah keberadaan baris yang identik. Baris tersebut tidak langsung dihapus karena informasi ID atau varian item belum cukup lengkap untuk memastikan bahwa baris tersebut benar-benar merupakan duplikasi yang tidak valid. Oleh karena itu, baris tersebut dipertahankan dan diberi penanda untuk ditinjau.

Selain itu, terdapat pesanan yang tidak memiliki informasi waktu lengkap. Data seperti ini tidak dibuatkan tanggal baru secara artifisial. Untuk keperluan analisis bulanan, hanya periode dari nama file yang digunakan sehingga nilai tanggal yang tidak diketahui tetap tidak dipaksakan.

Total pembayaran juga memerlukan pembersihan karena beberapa nilai berbentuk teks rupiah dengan tanda titik sebagai pemisah ribuan. Format tersebut dibersihkan sehingga nilai pembayaran dapat digunakan sebagai data numerik.

Beberapa atribut lainnya belum memiliki interpretasi satuan yang dapat diverifikasi. Nilai diskon dan tiga komponen ongkos kirim dipertahankan sebagai nilai asli dan tidak digunakan sebagai indikator rupiah utama. Retur yang kosong juga tetap dianggap tidak diketahui dan tidak secara otomatis diasumsikan bernilai nol.

Outlier pada data numerik juga tidak langsung dihapus. Data tersebut hanya diberi penanda berdasarkan metode IQR sehingga tetap tersedia untuk dianalisis tanpa menghilangkan kemungkinan transaksi yang sebenarnya valid. Pendekatan ini digunakan agar proses cleaning tidak mengubah isi dataset secara berlebihan.

Dengan demikian, veracity pada proyek ini ditangani melalui proses validasi, pemberian flag kualitas, pembentukan aturan interpretasi, serta pemisahan antara data yang dapat digunakan langsung dan data yang masih memerlukan kehati-hatian.

2.2.5 Value

Value menggambarkan manfaat atau nilai yang dapat diperoleh setelah data diolah dan dianalisis. Dataset memiliki nilai karena dapat digunakan untuk mengetahui pola aktivitas transaksi e-commerce berdasarkan waktu, produk, lokasi, dan status pesanan. Dari data tersebut dapat diketahui perubahan jumlah transaksi dari bulan ke bulan, nilai pembayaran pesanan selesai, kategori produk yang sering muncul, wilayah dengan kontribusi pembayaran terbesar, serta distribusi status pesanan.

Informasi tersebut dapat dimanfaatkan untuk mendukung pengambilan keputusan. Sebagai contoh, kategori yang sering muncul dalam transaksi dapat menjadi bahan pertimbangan dalam pengelolaan stok, sedangkan provinsi dengan pembayaran tinggi dapat menjadi fokus dalam perencanaan distribusi dan layanan.

Selain itu, analisis status pesanan dapat membantu melihat proporsi transaksi yang selesai maupun dibatalkan. Informasi tersebut dapat digunakan untuk mengidentifikasi bagian proses transaksi yang memerlukan perhatian lebih lanjut.

Hasil analisis kemudian disajikan dalam bentuk EDA dan dashboard sehingga informasi yang semula berupa data mentah dapat diubah menjadi visualisasi dan insight yang lebih mudah dipahami.

2.3 Kesimpulan Analisis 5V

Berdasarkan konsep 5V, dataset e-commerce yang digunakan memiliki karakteristik yang sesuai untuk dianalisis sebagai data berskala besar. Aspek Volume terlihat dari banyaknya transaksi dan baris item, Velocity dari pertumbuhan transaksi berdasarkan waktu, Variety dari keragaman tipe dan tingkat data, Veracity dari berbagai permasalahan kualitas yang memerlukan proses pembersihan, dan Value dari insight bisnis yang dapat diperoleh setelah data dianalisis.

BAB III TAHAPAN PEMBERSIHAN DATA

3.1 Tujuan Pembersihan Data

Sebelum dilakukan *Exploratory Data Analysis* (EDA), data mentah terlebih dahulu melalui proses pembersihan atau *data cleaning*. Tahapan ini bertujuan untuk memastikan bahwa data yang digunakan memiliki struktur yang konsisten, tipe data yang sesuai, serta aturan interpretasi yang jelas.

Proses cleaning dilakukan menggunakan Python dengan library Pandas pada Google Colab. Data yang digunakan merupakan data mentah dari folder RAW_PUBLIC. Data mentah tidak dimodifikasi secara langsung, sedangkan hasil proses cleaning disimpan sebagai dataset baru pada folder hasil_cleaning.

Pembersihan data pada proyek ini tidak dilakukan dengan prinsip menghapus seluruh data yang dianggap tidak biasa. Setiap permasalahan diperiksa berdasarkan konteks datanya. Data yang belum dapat dipastikan salah tetap dipertahankan dan diberi penanda agar informasi asli tidak hilang.

3.2 Penggabungan dan Pemilihan Data

Tahap awal dilakukan dengan membaca dan menggabungkan data transaksi yang berasal dari beberapa file bulanan. Setiap baris tetap diberikan informasi `source_file` sehingga asal data dapat ditelusuri kembali apabila ditemukan masalah pada proses analisis.

Setelah data digabungkan, dipilih atribut yang relevan dengan tujuan analisis. Beberapa atribut utama yang dipertahankan meliputi:

- `order_id`
- `product_category`
- status pesanan
- alasan pembatalan
- opsi pengiriman
- waktu pesanan dibuat
- metode pembayaran
- jumlah item
- jumlah retur
- total diskon
- total berat
- ongkos kirim
- total pembayaran
- kota/kabupaten
- provinsi
- sumber file

Selain kolom asli tersebut, proses cleaning juga menghasilkan beberapa kolom baru seperti `status_kelompok`, `periode_analisis`, `jumlah_item`, `jumlah_retur`, `berat_tercatat_gr`, dan `total_pembayaran_rp`.

3.3 Pemeriksaan Order ID

`order_id` merupakan atribut penting karena digunakan sebagai identitas untuk membentuk data pada tingkat pesanan. Sebelum proses agregasi dilakukan, sistem memeriksa apakah terdapat `order_id` yang kosong. Apabila ditemukan `order_id` kosong, proses agregasi dihentikan karena data tersebut berpotensi menyebabkan pesanan hilang atau tergabung secara tidak tepat.

Setiap baris data kemudian diberikan `id_baris_audit`. ID ini bukan bagian dari dataset asli, tetapi digunakan sebagai identitas internal untuk mempermudah penelusuran apabila ditemukan data yang melanggar aturan validasi.

3.4 Penanganan Missing Value

Nilai kosong tidak langsung diganti dengan angka nol atau nilai lainnya karena nilai kosong dapat memiliki arti yang berbeda untuk setiap atribut.

3.4.1 Data Retur

Nilai kosong pada jumlah retur dipertahankan sebagai tidak diketahui, bukan dianggap sebagai tidak adanya retur. Sebuah kolom penanda `retur_tidak_diketahui` dibuat untuk mengidentifikasi kondisi tersebut.

Jika dalam satu pesanan terdapat setidaknya satu item yang tidak memiliki informasi retur, maka total retur pada pesanan tersebut juga dianggap tidak diketahui. Keputusan ini dilakukan agar nilai nol hanya digunakan ketika memang diketahui bahwa tidak terdapat retur, bukan sebagai pengganti data yang tidak tersedia.

3.4.2 Waktu Pesanan

Sebagian data tidak memiliki informasi waktu pesanan secara lengkap. Data tersebut tidak diberikan tanggal buatan karena hal tersebut dapat menghasilkan informasi yang sebenarnya tidak terdapat pada sumber.

Sebagai gantinya, untuk analisis pada tingkat bulan digunakan `periode_analisis`. Jika waktu pesanan tersedia, periode diperoleh dari waktu tersebut. Apabila waktu pesanan tidak tersedia, periode analisis menggunakan bulan dari nama file sumber.

Data tersebut masih dapat digunakan untuk analisis bulanan, tetapi tidak digunakan untuk analisis yang membutuhkan waktu secara lebih rinci seperti analisis harian, jam transaksi, atau lama pengiriman.

3.5 Standardisasi Status Pesanan

Status pesanan pada data mentah kemudian dikelompokkan ke dalam kategori yang lebih konsisten agar lebih mudah dianalisis.

Beberapa kelompok status utama yang dipertahankan antara lain:

- Selesai
- Batal
- Dalam Pengiriman
- Diterima (masa pengembalian)

Status-status tersebut tidak digabungkan secara sembarangan karena masing-masing menunjukkan kondisi transaksi yang berbeda.

Pemisahan ini penting karena sebagian besar analisis keuangan pada proyek dilakukan menggunakan pesanan dengan kelompok status Selesai.

3.6 Pembersihan Total Pembayaran

Kolom Total Pembayaran pada data sumber memiliki format teks rupiah. Sebagian nilai menggunakan tanda titik sebagai pemisah ribuan. Sebelum dilakukan analisis, format tersebut dibersihkan sehingga nilai dapat dikonversi menjadi data numerik dan disimpan dalam variabel `total_pembayaran_rp`.

Sebagai contoh, nilai berbentuk: 150.000 dibaca sebagai: 150000. Tanda titik dihilangkan sebagai pemisah ribuan, sedangkan angka yang sejak awal tidak memiliki titik tetap dipertahankan pada nilainya.

Nilai total pembayaran kemudian digunakan dalam analisis transaksi pada tingkat pesanan. Namun, total pembayaran tidak secara otomatis diinterpretasikan sebagai laba perusahaan maupun nilai penjualan bersih produk karena dataset tidak menyediakan seluruh komponen yang diperlukan untuk menghitung indikator tersebut.

3.7 Penanganan Diskon dan Ongkos Kirim

Dataset juga memiliki beberapa atribut yang berkaitan dengan biaya, yaitu:

- Total Diskon
- Ongkos Kirim Dibayar oleh Pembeli
- Estimasi Potongan Biaya Pengiriman
- Perkiraan Ongkos Kirim

Nilai pada keempat atribut tersebut dapat dikonversi menjadi numerik. Namun, skala rupiahnya belum dapat diverifikasi dengan pasti berdasarkan informasi sumber.

Oleh karena itu, nilai tersebut tidak dikalikan dengan 1.000 atau diubah secara asumtif. Data disimpan sebagai nilai_asli dan diberikan penanda bahwa skala ongkir serta diskon belum terverifikasi. Keputusan ini menyebabkan diskon dan ongkir tidak digunakan sebagai KPI rupiah utama dalam analisis.

Selain itu, apabila nilai diskon atau ongkir berbeda antaritem dalam satu pesanan, nilai tersebut tidak dijumlahkan karena belum diketahui secara pasti apakah nilai tersebut merupakan biaya per item atau biaya lain pada tingkat transaksi.

3.8 Validasi Logis Data

Setelah proses konversi, dilakukan pemeriksaan terhadap nilai-nilai yang secara logis tidak sesuai. Beberapa kondisi yang diperiksa antara lain:

1. jumlah item kosong atau kurang dari atau sama dengan nol;
2. berat barang kosong atau kurang dari atau sama dengan nol;
3. total pembayaran kosong atau bernilai negatif;
4. jumlah retur bernilai negatif;
5. jumlah retur lebih besar daripada jumlah item;
6. nilai diskon atau ongkir yang telah dikonversi memiliki nilai negatif.

Jika ditemukan data yang melanggar aturan tersebut, proses cleaning tidak langsung menghapus baris terkait. Sebaliknya, program menghentikan proses dan memberikan ID baris yang perlu diperiksa. Dengan demikian, kesalahan data tidak disembunyikan melalui penghapusan otomatis.

3.9 Penanganan Baris Identik

Salah satu temuan pada dataset adalah adanya beberapa baris yang memiliki isi identik. Pada proses cleaning biasa, baris yang sama sering dianggap sebagai duplikat dan langsung dihapus. Namun, pendekatan tersebut tidak digunakan dalam proyek ini.

Hal ini disebabkan dataset tidak memiliki informasi identitas item atau varian produk yang cukup lengkap untuk memastikan bahwa dua baris yang sama benar-benar merupakan pencatatan ganda. Dua baris identik masih mungkin berasal dari dua item atau varian berbeda yang informasi identitasnya tidak tersedia.

Oleh karena itu, baris tersebut tidak dihapus. Sebagai gantinya, dibuat variabel: `baris_identik_perlu_tinjau` untuk memberikan tanda bahwa baris tersebut memiliki pasangan dengan nilai identik dan perlu diperhatikan ketika melakukan interpretasi jumlah item. Dengan pendekatan ini, seluruh data asli tetap dipertahankan dan risiko kehilangan transaksi yang sebenarnya valid dapat dikurangi.

3.10 Pembentukan Data Tingkat Pesanan

Dataset mentah memiliki struktur di mana satu `order_id` dapat muncul pada beberapa baris karena sebuah pesanan dapat mengandung lebih dari satu item. Apabila analisis jumlah transaksi dan pembayaran dilakukan langsung pada data item, hasilnya berpotensi mengalami *double counting*.

Oleh karena itu, setelah proses cleaning, data dikelompokkan berdasarkan `order_id`. Sebelum mengambil satu nilai untuk setiap pesanan, program terlebih dahulu memeriksa apakah atribut yang seharusnya sama dalam satu pesanan memang konsisten, seperti:

- status pesanan;
- metode pembayaran;
- opsi pengiriman;
- kota/kabupaten;
- provinsi;
- waktu pesanan;
- periode analisis;
- total pembayaran;
- total berat.

Apabila ditemukan nilai yang bertentangan untuk `order_id` yang sama, proses dihentikan sehingga nilai pertama tidak dipilih secara sembarangan. Setelah konsistensinya dipastikan, dibuat tabel baru dengan satu baris untuk setiap `order_id`.

Beberapa informasi tambahan yang dihitung pada tingkat pesanan antara lain jumlah baris item, jumlah item tercatat, jumlah kategori, kategori yang terdapat dalam pesanan, jumlah retur, serta penanda apakah pesanan memiliki baris identik.

Total pembayaran dan total berat yang konstan dalam satu pesanan hanya diambil satu kali, bukan dijumlahkan dari seluruh baris item.

Dengan demikian, terbentuk dua dataset utama:

1. `data_item_bersih.csv` → satu baris untuk setiap baris sumber/item.
2. `data_pesanan_bersih.csv` → satu baris untuk setiap `order_id`.

Untuk analisis jumlah pesanan dan nilai pembayaran digunakan `data_pesanan_bersih`, bukan `data_item`.

3.11 Deteksi Outlier

Setelah dataset pada tingkat pesanan terbentuk, dilakukan pemeriksaan *outlier* menggunakan metode Interquartile Range (IQR).

Outlier diperiksa pada tiga variabel utama, yaitu:

- `total_pembayaran_rp`
- `jumlah_item_tercatat`
- `berat_pesanan_gr`

Data referensi yang digunakan untuk menentukan batas IQR adalah pesanan dengan status Selesai dan total pembayaran lebih besar dari nol. Nilai Q1 dan Q3 dihitung terlebih dahulu, kemudian: $IQR = Q3 - Q1$. Batas bawah ditentukan menggunakan: $Q1 - 1,5 \times IQR$ sedangkan batas atas menggunakan: $Q3 + 1,5 \times IQR$. Nilai di luar batas tersebut diberi penanda sebagai outlier.

Namun, data outlier tidak dihapus dari dataset. Hal tersebut dilakukan karena nilai ekstrem tidak selalu menunjukkan kesalahan. Transaksi dengan jumlah barang, berat, atau pembayaran yang jauh lebih besar dibanding transaksi lain masih dapat merupakan transaksi yang valid.

Dengan demikian, metode IQR dalam proyek ini hanya digunakan sebagai penanda data untuk ditinjau, bukan sebagai dasar penghapusan otomatis.

3.12 Pemeriksaan Pembayaran Nol

Proses cleaning juga mengidentifikasi pesanan yang memiliki nilai: `total_pembayaran_rp = 0` tetapi statusnya bukan Batal. Pesanan tersebut diberikan penanda: `pembayaran_nol_nonbatal`. Data ini tetap dipertahankan karena nilai nol belum tentu merupakan kesalahan. Data hanya ditandai agar dapat diperhatikan pada proses analisis selanjutnya.

3.13 Audit Hasil Cleaning

Setelah seluruh proses cleaning selesai, dilakukan proses audit untuk memastikan bahwa transformasi data tidak menyebabkan kehilangan data atau penghitungan yang tidak sesuai.

Beberapa pemeriksaan yang dilakukan meliputi:

1. jumlah baris data item setelah cleaning harus sama dengan jumlah baris data mentah;
2. jumlah baris data pesanan harus sama dengan jumlah order_id unik;
3. order_id pada data pesanan harus unik;
4. seluruh baris item harus tetap terwakili dalam data pesanan;
5. nilai total pembayaran hanya dihitung satu kali untuk setiap pesanan;
6. missing value pada data retur harus tetap dipertahankan;
7. seluruh pesanan harus memiliki periode_analisis.

Pemeriksaan tersebut dilakukan menggunakan *assertion* sehingga proses akan menghasilkan error apabila salah satu syarat tidak terpenuhi.

Selain itu, dibuat laporan_kualitas.csv yang mencatat berbagai hasil pemeriksaan, seperti jumlah baris sebelum dan sesudah cleaning, jumlah pesanan unik, baris identik, missing value retur, waktu pesanan yang tidak tersedia, pembayaran nol nonbatal, dan jumlah outlier.

3.14 Hasil Akhir Pembersihan Data

Setelah proses cleaning dan validasi selesai, dihasilkan beberapa file sebagai berikut:

1. data_item_bersih.csv
Berisi data pada tingkat item beserta ID audit dan berbagai penanda kualitas data.
2. data_pesanan_bersih.csv
Berisi satu baris untuk setiap order_id dan digunakan sebagai dataset utama untuk analisis jumlah transaksi dan pembayaran.
3. laporan_kualitas.csv
Berisi hasil audit kualitas data serta tindakan yang dilakukan terhadap setiap permasalahan.

4. batas_outlier.csv

Berisi nilai Q1, Q3, IQR, batas bawah, batas atas, serta jumlah transaksi yang ditandai sebagai outlier.

5. CATATAN_CLEANING.txt

Berisi aturan dan batasan interpretasi data setelah cleaning.

Seluruh hasil kemudian dikumpulkan ke dalam file hasil_cleaning.zip. Berdasarkan hasil tersebut, data pada tingkat pesanan dinilai siap digunakan untuk analisis jumlah dan status pesanan, total pembayaran, periode bulanan, wilayah, metode pembayaran, dan opsi pengiriman. Sementara itu, analisis biaya diskon dan ongkir dalam rupiah belum dilakukan karena satuannya belum dapat diverifikasi.

BAB 4: EXPLORATORY DATA ANALYSIS (EDA)

4.1 Tujuan Exploratory Data Analysis

Setelah proses pembersihan data selesai, tahap berikutnya adalah Exploratory Data Analysis (EDA). EDA dilakukan untuk memahami pola utama yang terdapat dalam data sebelum menarik insight dan rekomendasi.

Analisis dilakukan menggunakan tabel data_pesanan_bersih.csv sebagai sumber utama untuk perhitungan jumlah pesanan dan pembayaran. Sementara itu, data_item_bersih.csv digunakan ketika analisis membutuhkan informasi kategori produk.

EDA pada proyek ini mencakup analisis:

1. distribusi status pesanan;
2. tren pesanan selesai dan pembayaran secara bulanan;
3. kategori produk dalam pesanan selesai;
4. distribusi transaksi berdasarkan provinsi;
5. metode pembayaran;
6. opsi pengiriman;
7. alasan pembatalan; dan
8. distribusi serta hubungan antara variabel numerik.

Paket EDA yang dihasilkan juga menyimpan setiap hasil analisis dalam bentuk tabel CSV dan visualisasi PNG untuk digunakan pada laporan.

4.2 Ringkasan Data Setelah Cleaning

Berdasarkan data yang telah dibersihkan, terdapat 20.848 pesanan selama periode Desember 2023 sampai November 2025.

Dari seluruh pesanan tersebut:

- 17.768 pesanan berstatus Selesai;
- 2.830 pesanan berstatus Batal;
- 161 pesanan berstatus Diterima (masa pengembalian); dan
- 89 pesanan berstatus Dalam pengiriman.

Dengan demikian, pesanan selesai mencakup sekitar 85,23% dari seluruh data pesanan, sedangkan pesanan batal sekitar 13,57%.

Total pembayaran untuk pesanan yang telah selesai mencapai Rp1.045.550.734, dengan rata-rata pembayaran sebesar sekitar Rp58.844,59 per pesanan.

Median pembayaran hanya sebesar Rp26.128,50, jauh lebih rendah dibandingkan rata-rata. Perbedaan tersebut menunjukkan bahwa distribusi nilai pembayaran tidak simetris dan terdapat sejumlah transaksi bernilai besar yang meningkatkan nilai rata-rata.


Selain itu, ditemukan 62 pesanan selesai dengan total pembayaran Rp0. Pesanan tersebut tetap dipertahankan karena pada tahap cleaning pembayaran nol tidak otomatis diasumsikan sebagai data yang salah.

4.3 Analisis Status Pesanan

Analisis pertama dilakukan terhadap distribusi status pesanan.

Hasil menunjukkan bahwa status Selesai mendominasi dataset dengan 17.768 pesanan atau sekitar 85,23%. Status berikutnya adalah Batal sebanyak 2.830 pesanan atau sekitar 13,57%.

Sementara itu, jumlah pesanan yang tercatat sebagai Diterima (masa pengembalian) dan Dalam pengiriman relatif kecil dibandingkan dua status utama.



Gambar 4.1 Distribusi Status Pesanan

Dominasi status selesai menunjukkan bahwa sebagian besar transaksi yang terdapat dalam dataset telah mencapai kondisi selesai pada saat data dicatat.

Namun, persentase pembatalan sebesar 13,57% tetap cukup berarti untuk dianalisis lebih lanjut. Perlu diperhatikan bahwa persentase ini menggambarkan status pada saat dataset dicatat, sehingga tidak dapat dianggap sebagai tingkat pembatalan akhir dari seluruh transaksi e-commerce secara umum.


4.4 Analisis Tren Pesanan Selesai dan Pembayaran Bulanan

Analisis temporal dilakukan dengan mengelompokkan transaksi berdasarkan periode_analisis.

Untuk setiap bulan dihitung:

- seluruh pesanan;
- jumlah pesanan selesai;
- jumlah pesanan batal;
- jumlah status lainnya;
- total pembayaran pesanan selesai;
- persentase pesanan batal; dan
- rata-rata pembayaran pesanan selesai.

Dashboard dan EDA menghitung pembayaran berdasarkan pesanan berstatus Selesai, serta memastikan pembayaran hanya dihitung satu kali untuk setiap order_id.



Gambar 4.2 Tren Pesanan dan Pembayaran Bulanan

4.4.1 Tren Jumlah Pesanan

Jumlah pesanan selesai mengalami perubahan dari bulan ke bulan. Pada awal periode, yaitu Desember 2023, terdapat 352 pesanan selesai. Aktivitas transaksi kemudian mengalami peningkatan yang cukup besar sepanjang 2024.

Jumlah pesanan selesai tertinggi terjadi pada Juli 2024, yaitu sebanyak 1.114 pesanan selesai dari total 1.270 pesanan pada bulan tersebut.

Setelah itu, jumlah transaksi tetap relatif tinggi pada beberapa bulan berikutnya. Pada tahun 2025, transaksi kembali menunjukkan peningkatan menjelang akhir periode, salah satunya pada Oktober 2025 dengan 1.092 pesanan selesai.

Data November 2025 memiliki karakteristik berbeda karena masih terdapat 250 transaksi dengan status selain selesai dan batal. Oleh karena itu, penurunan jumlah pesanan selesai pada bulan tersebut tidak sebaiknya langsung diartikan sebagai penurunan aktivitas penjualan.

4.4.2 Tren Pembayaran

Nilai pembayaran pesanan selesai juga berubah dari bulan ke bulan. Pembayaran tertinggi terjadi pada September 2024, yaitu sekitar Rp71.193.097.


Temuan ini menarik karena bulan dengan pembayaran terbesar tidak sama dengan bulan dengan jumlah pesanan selesai terbanyak. Jumlah pesanan tertinggi terjadi pada Juli 2024, sedangkan nilai pembayaran tertinggi terjadi pada September 2024.

Dengan demikian, tingginya jumlah transaksi tidak selalu menghasilkan nilai pembayaran tertinggi. Nilai transaksi per pesanan juga memiliki pengaruh terhadap total pembayaran setiap bulan.

Sebagai contoh, pada Maret 2025 terdapat 516 pesanan selesai dengan rata-rata pembayaran sekitar Rp84.670 per pesanan, lebih tinggi dibandingkan banyak bulan lainnya walaupun jumlah pesannya tidak termasuk yang tertinggi.

4.5 Analisis Kategori Produk

Analisis selanjutnya dilakukan untuk mengetahui kategori produk yang paling sering terdapat dalam pesanan berstatus Selesai. Perhitungan dilakukan berdasarkan pasangan unik antara `order_id` dan `product_category`. Dengan demikian, kategori yang sama tidak dihitung lebih dari satu kali apabila muncul berulang dalam pesanan yang sama. Metode ini juga berarti sebuah pesanan yang mengandung beberapa kategori dapat tercatat pada lebih dari satu kategori.



Gambar 4.3 Kategori Produk pada Pesanan Selesai

Kategori yang paling sering muncul adalah:


1. Celengan, terdapat dalam 5.188 pesanan selesai atau sekitar 29,20% dari seluruh pesanan selesai;
2. Mangkok Sambal / Saus, sebanyak 3.398 pesanan atau sekitar 19,12%;
3. Aksesoris Pintu, sebanyak 2.654 pesanan atau sekitar 14,94%;
4. Nampan / Tray, sebanyak 1.288 pesanan atau sekitar 7,25%; dan
5. Other, sebanyak 729 pesanan atau sekitar 4,10%.

Hasil menunjukkan adanya konsentrasi pesanan pada beberapa kategori tertentu, terutama Celengan, Mangkok Sambal/Saus, dan Aksesoris Pintu. Terdapat pula 1.290 pesanan selesai yang mengandung lebih dari satu kategori. Oleh karena itu, persentase seluruh kategori tidak harus berjumlah 100%.

Analisis ini menunjukkan frekuensi kategori dalam pesanan, bukan jumlah unit yang terjual. Selain itu, total pembayaran suatu pesanan tidak diberikan sepenuhnya kepada setiap kategori karena satu pesanan dapat memiliki beberapa kategori produk dan dataset tidak menyediakan nilai item yang memadai untuk melakukan alokasi pembayaran secara akurat.

4.6 Analisis Berdasarkan Provinsi

Analisis wilayah dilakukan dengan mengelompokkan transaksi berdasarkan provinsi dan menghitung jumlah pesanan serta total pembayaran pesanan selesai.



Gambar 4.4 Distribusi Transaksi Berdasarkan Wilayah

Provinsi dengan kontribusi pembayaran pesanan selesai terbesar adalah Jawa Barat, dengan nilai sekitar Rp275.388.979 atau 26,34% dari seluruh pembayaran pesanan selesai.

Beberapa wilayah dengan kontribusi berikutnya adalah:


- Banten: sekitar Rp176.844.990 atau 16,91%;
- DKI Jakarta: sekitar Rp134.953.842 atau 12,91%;
- Jawa Tengah: sekitar Rp99.390.647 atau 9,51%; dan
- Jawa Timur: sekitar Rp94.724.345 atau 9,06%.

Jawa Barat juga memiliki jumlah transaksi terbesar, yaitu 6.664 pesanan, dengan 5.851 di antaranya berstatus selesai. Hasil tersebut menunjukkan bahwa transaksi dalam dataset cukup terkonsentrasi di wilayah Pulau Jawa, khususnya Jawa Barat, Banten, DKI Jakarta, Jawa Tengah, dan Jawa Timur.

Namun, kontribusi pembayaran yang besar tidak dapat langsung diartikan sebagai ukuran keseluruhan pasar e-commerce pada provinsi tersebut. Hasil hanya menggambarkan distribusi transaksi yang terdapat pada dataset yang digunakan.

4.7 Analisis Metode Pembayaran

Analisis metode pembayaran dilakukan untuk mengetahui metode yang paling sering digunakan serta melihat proporsi pembatalan pada masing-masing metode.



Gambar 4.5 Metode Pembayaran

Metode pembayaran yang paling banyak digunakan adalah COD (Bayar di Tempat) dengan total 11.538 pesanan. Dari jumlah tersebut:


- 9.822 pesanan selesai;
- 1.544 pesanan batal; dan
- sisanya berada pada status lainnya.

Proporsi pesanan batal pada COD adalah sekitar 13,38%. Metode berikutnya yang banyak digunakan adalah Saldo ShopeePay sebanyak 3.692 pesanan dan Online Payment sebanyak 3.170 pesanan. Jika hanya mempertimbangkan metode dengan sedikitnya 100 pesanan, Online Payment memiliki proporsi pembatalan tertinggi, yaitu sekitar 18,55%, dengan 588 pesanan batal dari 3.170 pesanan.

Meskipun terdapat perbedaan proporsi pembatalan, hasil tersebut tidak membuktikan bahwa jenis metode pembayaran menjadi penyebab pembatalan. Faktor pelanggan, wilayah, waktu, produk, maupun proses transaksi lainnya belum dikendalikan dalam analisis deskriptif ini.

4.8 Analisis Opsi Pengiriman

EDA berikutnya dilakukan terhadap opsi pengiriman yang digunakan dalam transaksi.



Gambar 4.6 Opsi Pengiriman

Opsi pengiriman yang paling banyak tercatat adalah Hemat Kargo-SPX Hemat, dengan total 12.597 pesanan.

Dari jumlah tersebut, sebanyak:

- 11.023 pesanan selesai;
- 1.356 pesanan batal; dan
- 218 pesanan berada pada status lainnya.

Persentase pembatalannya sekitar 10,76%. Opsi berikutnya adalah Reguler (Cashless)-SPX Standard dengan 4.622 pesanan dan persentase pembatalan sekitar 8,18%. Terdapat pula label Hemat Kargo sebanyak 460 pesanan yang seluruhnya berstatus Batal. Namun, kondisi ini tidak dapat digunakan untuk menyimpulkan bahwa layanan pengiriman tersebut menyebabkan pembatalan.

Sebanyak 253 dari 460 pesanan pada kelompok tersebut memiliki alasan pesanan belum dibayar. Selain itu, label Hemat Kargo tidak menyebutkan kurir secara spesifik sehingga kemungkinan terdapat perbedaan struktur pencatatan pada dataset.

Hal serupa juga ditemukan pada label Reguler (Cashless) tanpa nama kurir. Seluruh 190 transaksi pada label tersebut tercatat batal, tetapi kondisi ini tetap tidak cukup untuk menunjukkan hubungan sebab-akibat dengan layanan pengiriman.

4.9 Analisis Alasan Pembatalan

Karena terdapat 2.830 pesanan berstatus Batal, dilakukan analisis lebih lanjut terhadap alasan pembatalannya



Gambar 4.7 Alasan Pembatalan Pesanan

Alasan pembatalan yang paling banyak tercatat adalah: “Dibatalkan oleh Pembeli. Alasan: Lainnya/berubah pikiran” dengan 662 pesanan, atau sekitar 23,39% dari seluruh pesanan batal.

Alasan berikutnya adalah:

- mengubah pesanan yang ada: 558 pesanan atau 19,72%;
- pesanan belum dibayar dan dibatalkan otomatis: 447 pesanan atau 15,80%;
- perubahan alamat pengiriman: 306 pesanan atau 10,81%;
- pengiriman gagal: 255 pesanan atau 9,01%.


Hasil menunjukkan bahwa sebagian besar pembatalan yang tercatat berkaitan dengan keputusan atau perubahan dari sisi pembeli. Namun, terdapat pula pembatalan otomatis yang berkaitan dengan pembayaran maupun proses pengiriman.

Label alasan pembatalan dipertahankan sesuai data sumber sehingga terdapat beberapa kategori dengan arti yang hampir sama tetapi memiliki variasi bahasa atau penulisan.

4.10 Analisis Distribusi Variabel Numerik

EDA juga dilakukan terhadap tiga variabel numerik pada pesanan selesai, yaitu:

- total pembayaran;
- berat pesanan; dan
- jumlah item tercatat.



Gambar 4.8 Distribusi dan Hubungan Variabel Numerik

4.10.1 Total Pembayaran

Untuk 17.768 pesanan selesai, diperoleh:

- rata-rata: Rp58.844,59;
- median: Rp26.128,50;

- kuartil pertama (Q1): Rp17.640;
- kuartil ketiga (Q3): Rp47.500; dan
- maksimum: Rp3.403.591.

Nilai maksimum yang jauh lebih besar dibandingkan median memperlihatkan keberadaan sejumlah pesanan bernilai tinggi.

Rata-rata yang lebih dari dua kali median juga menunjukkan bahwa distribusi pembayaran mengalami kemencengan ke kanan (*right-skewed*). Oleh karena itu, median lebih representatif untuk menggambarkan nilai transaksi yang umum, sedangkan rata-rata tetap penting untuk melihat nilai pembayaran secara keseluruhan.

4.10.2 Berat Pesanan

Median berat pesanan selesai adalah sekitar 500 gram, sementara rata-ratanya sekitar 1.290,74 gram. Sebagian besar transaksi memiliki berat relatif rendah, sedangkan beberapa transaksi dengan berat sangat besar meningkatkan nilai rata-rata. Berat maksimum yang tercatat mencapai 98.000 gram.

Seperti pada pembayaran, nilai ekstrem tidak langsung dihapus karena masih mungkin merupakan transaksi yang valid.

4.10.3 Jumlah Item Tercatat

Median jumlah item pada pesanan selesai adalah 1 item, sedangkan rata-rata sekitar 2,49 item. Sebagian besar transaksi dengan demikian memiliki jumlah item yang kecil. Akan tetapi, terdapat beberapa pesanan dengan jumlah item jauh lebih banyak, dengan maksimum mencapai 256 item tercatat.

Interpretasi jumlah item tetap perlu dilakukan dengan hati-hati karena pada tahap cleaning ditemukan baris identik yang tidak dapat dipastikan sebagai duplikasi akibat keterbatasan identitas item.

4.11 Analisis Korelasi Berat dan Pembayaran

Untuk melihat hubungan antara berat pesanan dan total pembayaran, digunakan korelasi Spearman pada 17.768 pesanan selesai. Hasil perhitungan menghasilkan koefisien: $\rho = 0,743$

Nilai tersebut menunjukkan terdapat hubungan positif yang cukup kuat antara berat pesanan dan nilai pembayaran. Artinya, secara umum pesanan dengan berat yang lebih tinggi cenderung memiliki nilai pembayaran yang lebih tinggi pula.

Namun, korelasi tersebut tidak berarti bahwa peningkatan berat menyebabkan peningkatan pembayaran. Berat pesanan dapat berkaitan dengan jumlah barang, jenis produk, harga produk, atau karakteristik transaksi lainnya. Oleh karena itu, hasil korelasi hanya digunakan sebagai temuan eksploratif dan bukan sebagai hubungan sebab-akibat.

4.12 Dashboard Interaktif

Selain grafik EDA individual, hasil analisis juga disajikan dalam bentuk dashboard interaktif. Dashboard menyediakan tiga filter utama, yaitu:

- Kategori produk;
- Provinsi; dan
- Rentang bulan.

Setelah filter dipilih, dashboard menghitung ulang jumlah seluruh pesanan, jumlah pesanan selesai, persentase pesanan batal, total pembayaran pesanan selesai, dan rata-rata pembayaran pesanan selesai.

Visualisasi di dalam dashboard meliputi:

1. tren pembayaran pesanan selesai per bulan;
2. kategori yang paling sering muncul;
3. provinsi dengan pembayaran terbesar; dan
4. distribusi status pesanan.

Filter kategori bekerja dengan memilih pesanan yang memuat kategori tersebut. Jika sebuah pesanan mengandung beberapa kategori, pembayaran yang ditampilkan tetap merupakan nilai seluruh pesanan sehingga tidak boleh diinterpretasikan sebagai omzet khusus kategori tersebut.

Dashboard digunakan untuk mempermudah eksplorasi karena pengguna dapat membandingkan pola transaksi berdasarkan kategori, wilayah, dan waktu tanpa melakukan agregasi secara manual.

4.13 Ringkasan Hasil EDA

Berdasarkan EDA, diperoleh beberapa pola utama. Sebagian besar pesanan dalam dataset telah berstatus selesai, tetapi masih terdapat pembatalan sebesar sekitar 13,57%. Aktivitas transaksi berubah cukup signifikan antarbulan dan jumlah transaksi tertinggi tidak selalu bertepatan dengan nilai pembayaran tertinggi.

Kategori Celengan merupakan kategori yang paling sering terdapat dalam pesanan selesai, sedangkan Jawa Barat menjadi provinsi dengan jumlah transaksi dan kontribusi pembayaran terbesar. COD merupakan metode pembayaran paling banyak digunakan dan Hemat Kargo-SPX Hemat merupakan opsi pengiriman yang paling banyak tercatat.

Analisis distribusi juga menunjukkan bahwa pembayaran memiliki distribusi yang tidak simetris karena terdapat transaksi bernilai besar. Sementara itu, berat pesanan memiliki korelasi positif yang cukup kuat dengan nilai pembayaran, meskipun hubungan tersebut tidak dapat ditafsirkan sebagai hubungan sebab-akibat.

Hasil EDA ini selanjutnya digunakan sebagai dasar dalam menyusun insight dan rekomendasi pada Bab V.

BAB V INSIGHT DAN REKOMENDASI

5.1 Insight Utama

Berdasarkan hasil *Exploratory Data Analysis* terhadap data e-commerce periode Desember 2023 sampai November 2025, diperoleh beberapa insight utama mengenai pola transaksi, pembayaran, produk, wilayah, dan status pesanan.

5.1.1 Perkembangan Jumlah Pesanan

Dari keseluruhan 20.848 pesanan, sebanyak 17.768 pesanan atau sekitar 85,23% tercatat berstatus Selesai. Sementara itu, sebanyak 2.830 pesanan atau sekitar 13,57% berstatus Batal.

Jumlah pesanan selesai mengalami perubahan dari bulan ke bulan. Aktivitas transaksi meningkat cukup tinggi selama tahun 2024 dan mencapai jumlah pesanan selesai tertinggi pada Juli 2024, yaitu sebanyak 1.114 pesanan selesai. Pada tahun 2025, jumlah transaksi tetap mengalami fluktuasi dan kembali mencapai tingkat yang relatif tinggi pada Oktober 2025 dengan 1.092 pesanan selesai.

Hal tersebut menunjukkan bahwa aktivitas transaksi pada dataset tidak berlangsung secara konstan. Terdapat periode tertentu dengan aktivitas transaksi yang jauh lebih tinggi dibandingkan periode lainnya.

Insight: Perusahaan perlu memperhatikan pola peningkatan transaksi secara periodik karena bulan dengan volume transaksi tinggi membutuhkan kesiapan stok, proses pemenuhan pesanan, dan kapasitas pengiriman yang lebih besar.

5.2 Insight Tren Nilai Pembayaran

Total pembayaran dari seluruh pesanan berstatus Selesai adalah sekitar Rp1.045.550.734, dengan rata-rata sekitar Rp58.844,59 per pesanan. Nilai pembayaran tertinggi secara bulanan terjadi pada September 2024, yaitu sekitar Rp71.193.097.

Temuan tersebut berbeda dengan hasil analisis jumlah pesanan. Jumlah pesanan selesai paling tinggi terjadi pada Juli 2024, sedangkan nilai pembayaran tertinggi terjadi pada September 2024.

Hal ini menunjukkan bahwa: jumlah pesanan yang tinggi tidak selalu menghasilkan nilai pembayaran yang paling tinggi. Perbedaan tersebut dapat terjadi karena nilai transaksi setiap pesanan berbeda-beda.

Sebagai contoh, bulan dengan jumlah transaksi lebih rendah masih dapat menghasilkan pembayaran yang besar apabila terdapat lebih banyak transaksi dengan nilai tinggi. Distribusi pembayaran juga menunjukkan perbedaan antara rata-rata dan median. Rata-rata pembayaran adalah sekitar Rp58.844,59, sedangkan median hanya sekitar Rp26.128,50.

Nilai rata-rata yang jauh lebih tinggi dibandingkan median menunjukkan bahwa terdapat sejumlah transaksi bernilai besar yang meningkatkan rata-rata keseluruhan.

Insight: Dalam mengevaluasi kinerja transaksi, jumlah pesanan dan nilai pembayaran sebaiknya dianalisis secara bersamaan. Volume transaksi saja belum cukup untuk menggambarkan nilai ekonomi dari transaksi pada suatu periode.

5.3 Insight Kategori Produk

Kategori produk yang paling sering terdapat dalam pesanan berstatus Selesai adalah Celengan, yang muncul pada sekitar 5.188 pesanan selesai atau 29,20%.

Kategori berikutnya adalah:

1. Mangkok Sambal / Saus : 3.398 pesanan;
2. Aksesoris Pintu : 2.654 pesanan;
3. Nampan / Tray : 1.288 pesanan;
4. Other : 729 pesanan.

Hasil tersebut menunjukkan adanya konsentrasi transaksi pada beberapa kategori tertentu. Kategori Celengan memiliki frekuensi kemunculan yang jauh lebih tinggi dibandingkan

sebagian besar kategori lainnya sehingga dapat dianggap sebagai salah satu kategori yang memiliki aktivitas transaksi tinggi pada dataset.

Namun, hasil tersebut tidak dapat langsung disebut sebagai kategori dengan omzet tertinggi. Hal ini karena satu pesanan dapat memiliki beberapa kategori produk dan pembayaran tersedia pada tingkat pesanan, bukan pada tingkat masing-masing item.

Dalam dashboard, suatu pesanan yang memiliki kategori tertentu dipilih berdasarkan keberadaan kategori tersebut, tetapi nilai pembayaran tetap merupakan pembayaran seluruh pesanan.

Insight: Kategori dengan frekuensi pesanan tinggi, terutama Celengan, Mangkok Sambal/Saus, dan Aksesoris Pintu, dapat menjadi prioritas dalam perencanaan persediaan. Namun, analisis profitabilitas atau omzet kategori membutuhkan informasi harga atau nilai transaksi pada tingkat item.

5.4 Insight Berdasarkan Wilayah

Analisis berdasarkan provinsi menunjukkan bahwa Jawa Barat merupakan wilayah dengan kontribusi pembayaran terbesar. Total pembayaran pesanan selesai dari Jawa Barat mencapai sekitar: Rp275.388.979 atau sekitar 26,34% dari seluruh pembayaran pesanan selesai.

Wilayah dengan kontribusi besar berikutnya adalah:

- Banten : sekitar 16,91%;
- DKI Jakarta : sekitar 12,91%;
- Jawa Tengah : sekitar 9,51%;
- Jawa Timur : sekitar 9,06%.

Jawa Barat juga memiliki jumlah transaksi paling besar, yaitu sekitar 6.664 pesanan, dengan 5.851 di antaranya berstatus Selesai. Hasil tersebut menunjukkan bahwa aktivitas transaksi pada dataset cukup terkonsentrasi pada Pulau Jawa.

Insight: Wilayah dengan volume transaksi dan pembayaran besar, khususnya Jawa Barat, Banten, dan DKI Jakarta, memiliki peran penting dalam aktivitas transaksi dataset. Wilayah tersebut dapat menjadi prioritas dalam perencanaan kapasitas distribusi dan pelayanan pelanggan.

Namun, hasil ini tidak berarti bahwa wilayah dengan transaksi rendah memiliki permintaan e-commerce yang rendah secara umum. Dataset yang digunakan hanya menggambarkan transaksi yang tersedia pada sumber data.

5.5 Insight Status dan Pembatalan Pesanan

Sebagian besar pesanan berhasil mencapai status Selesai. Namun, masih terdapat 2.830 pesanan batal, yaitu sekitar 13,57% dari seluruh pesanan.

Analisis terhadap alasan pembatalan menunjukkan bahwa alasan paling umum adalah: “Dibatalkan oleh Pembeli. Alasan: Lainnya/berubah pikiran” sebanyak 662 pesanan atau sekitar 23,39% dari seluruh transaksi batal.

Alasan lain yang cukup sering muncul antara lain:

- pembeli ingin mengubah pesanan;
- pesanan belum dibayar;
- perubahan alamat pengiriman;
- pengiriman gagal.

Hal tersebut menunjukkan bahwa pembatalan tidak hanya berkaitan dengan proses pengiriman. Sebagian besar pembatalan berasal dari keputusan atau perubahan kondisi dari sisi pembeli.

Insight: Pengurangan pembatalan dapat difokuskan pada pengalaman pelanggan sebelum transaksi dikonfirmasi, misalnya melalui informasi produk dan pesanan yang lebih jelas serta kemudahan memeriksa kembali alamat dan isi pesanan sebelum menyelesaikan transaksi.

Selain itu, transaksi yang dibatalkan karena belum dibayar dapat menjadi indikator bahwa proses pembayaran juga perlu diperhatikan.

5.6 Insight Metode Pembayaran

Metode pembayaran yang paling banyak digunakan pada dataset adalah COD (Bayar di Tempat) dengan sekitar 11.538 pesanan. Sebagian besar transaksi COD berhasil selesai, tetapi sekitar 1.544 transaksi tercatat dibatalkan.

Sementara itu, Online Payment memiliki proporsi pembatalan yang relatif tinggi, yaitu sekitar 18,55%, apabila dibandingkan dengan metode pembayaran yang memiliki sedikitnya 100 transaksi.

Namun, analisis tersebut masih bersifat deskriptif. Metode pembayaran tidak dapat langsung dianggap sebagai penyebab terjadinya pembatalan karena faktor lain, seperti kategori produk, pelanggan, waktu transaksi, dan wilayah, belum dikendalikan.

Insight: Metode pembayaran dapat digunakan sebagai salah satu dimensi untuk memantau tingkat keberhasilan transaksi, tetapi dibutuhkan analisis lanjutan sebelum menyimpulkan adanya pengaruh metode pembayaran terhadap pembatalan.

5.7 Insight Opsi Pengiriman

Opsi pengiriman yang paling sering digunakan adalah Hemat Kargo-SPX Hemat dengan sekitar 12.597 pesanan. Mayoritas transaksi menggunakan layanan tersebut berhasil selesai.

Namun, terdapat beberapa label pengiriman seperti Hemat Kargo tanpa nama kurir yang seluruh transaksinya tercatat berstatus Batal. Temuan tersebut perlu diinterpretasikan dengan hati-hati.

Sebagian transaksi tersebut memiliki alasan pembatalan karena pesanan belum dibayar. Oleh karena itu, tingginya pembatalan pada kelompok tersebut belum membuktikan bahwa layanan pengiriman menjadi penyebab pembatalan.

Insight: Analisis performa pengiriman sebaiknya tidak hanya berdasarkan status akhir pesanan. Dibutuhkan informasi tambahan seperti waktu pengiriman, keterlambatan, kegagalan pengiriman, serta waktu sejak pesanan dibuat hingga diterima untuk mengevaluasi layanan logistik secara lebih akurat.

5.8 Insight Hubungan Berat Pesanan dan Pembayaran

Analisis korelasi Spearman antara berat pesanan dan total pembayaran pada pesanan selesai menghasilkan nilai sekitar: $\rho = 0,743$

Nilai tersebut menunjukkan adanya hubungan positif yang cukup kuat antara kedua variabel. Secara umum, pesanan dengan berat lebih tinggi cenderung memiliki nilai pembayaran lebih tinggi.

Kondisi tersebut masuk akal karena berat pesanan dapat meningkat ketika pembeli membeli lebih banyak barang atau membeli produk berukuran lebih besar. Namun, hubungan ini tetap merupakan korelasi dan bukan bukti hubungan sebab-akibat.

Insight: Berat pesanan dapat menjadi salah satu indikator yang berkaitan dengan nilai transaksi, tetapi tidak dapat digunakan sendirian untuk memprediksi nilai pembayaran karena harga dan jenis produk juga memengaruhi nilai transaksi.

5.9 Rekomendasi

Berdasarkan hasil analisis, beberapa rekomendasi yang dapat diberikan adalah sebagai berikut.

1. Menyesuaikan stok dengan pola permintaan

Kategori dengan frekuensi transaksi tinggi seperti Celengan, Mangkok Sambal/Saus, dan Aksesoris Pintu dapat diberikan perhatian lebih dalam perencanaan persediaan. Terutama ketika mendekati periode dengan aktivitas transaksi tinggi, ketersediaan produk perlu dipastikan agar permintaan dapat dipenuhi dengan baik.

2. Mempersiapkan kapasitas pada periode transaksi tinggi

Jumlah transaksi mengalami fluktuasi cukup besar antarbulan. Periode dengan transaksi tinggi seperti pertengahan hingga akhir 2024 menunjukkan perlunya kapasitas pemrosesan pesanan dan distribusi yang lebih tinggi. Data historis dapat digunakan sebagai referensi dalam menentukan kebutuhan operasional pada periode berikutnya.

3. Memprioritaskan wilayah dengan aktivitas transaksi besar

Jawa Barat, Banten, DKI Jakarta, Jawa Tengah, dan Jawa Timur memiliki kontribusi transaksi dan pembayaran yang tinggi dalam dataset. Wilayah tersebut dapat menjadi prioritas dalam optimasi distribusi, ketersediaan stok di gudang terdekat, dan kapasitas layanan pengiriman.

4. Mengurangi pembatalan dari sisi pelanggan

Karena sebagian besar alasan pembatalan berasal dari perubahan keputusan pembeli, proses sebelum pesanan dikonfirmasi dapat diperbaiki. Informasi mengenai produk, harga, jumlah barang, alamat tujuan, dan detail pembayaran sebaiknya ditampilkan dengan jelas sebelum pelanggan menyelesaikan pesanan.

5. Memantau transaksi yang belum dibayar

Pembatalan karena pesanan belum dibayar merupakan salah satu alasan yang cukup sering muncul. Sistem dapat memberikan pengingat pembayaran sebelum batas waktu transaksi berakhir untuk membantu mengurangi pembatalan otomatis.

6. Tidak hanya menggunakan rata-rata sebagai indikator transaksi

Karena distribusi pembayaran memiliki nilai ekstrem, rata-rata dapat dipengaruhi oleh sebagian kecil transaksi bernilai besar. Oleh karena itu, laporan transaksi sebaiknya menggunakan kombinasi beberapa indikator seperti:

- jumlah pesanan;
- total pembayaran;
- rata-rata pembayaran; dan
- median pembayaran.

Penggunaan beberapa indikator menghasilkan gambaran aktivitas transaksi yang lebih representatif.

7. Melakukan analisis lanjutan terhadap pembatalan

Untuk mengetahui faktor yang paling berkaitan dengan pembatalan, dapat dilakukan analisis lanjutan dengan menggabungkan variabel seperti: metode pembayaran, kategori produk, provinsi, opsi pengiriman, waktu transaksi, dan alasan pembatalan. Analisis statistik atau model prediktif dapat digunakan pada tahap berikutnya untuk mengetahui faktor yang memiliki hubungan lebih kuat terhadap kemungkinan pembatalan.

5.10 Keterbatasan Analisis

Hasil analisis memiliki beberapa keterbatasan yang perlu diperhatikan.

Pertama, dataset merupakan data historis dari sumber yang tersedia sehingga tidak dapat dianggap mewakili seluruh aktivitas e-commerce di Indonesia.

Kedua, terdapat baris item identik yang tetap dipertahankan karena dataset tidak menyediakan identitas produk atau varian yang cukup untuk memastikan apakah baris tersebut benar-benar duplikat.

Ketiga, satuan nilai diskon dan beberapa komponen ongkos kirim belum dapat diverifikasi sehingga variabel tersebut tidak digunakan untuk menghitung indikator keuangan. Data cleaning secara eksplisit mempertahankan nilai tersebut sebagai nilai asli dan tidak menjadikannya KPI rupiah.

Keempat, total pembayaran tersedia pada tingkat pesanan sehingga pembayaran tidak dapat dibagi secara akurat ke setiap kategori produk. Karena itu, analisis kategori menunjukkan frekuensi kategori dalam pesanan, bukan omzet masing-masing kategori.

Kelima, status pesanan menggambarkan keadaan ketika data dicatat. Dengan demikian, khususnya untuk periode terakhir, pesanan yang masih berada pada proses pengiriman belum tentu akan tetap memiliki status tersebut pada akhirnya. Dashboard juga memperlakukan status sebagai keadaan pada saat pencatatan, bukan status akhir suatu kohor transaksi.

5.11 Kesimpulan

Berdasarkan analisis yang dilakukan, dataset e-commerce periode Desember 2023 sampai November 2025 menunjukkan bahwa sebagian besar pesanan berhasil diselesaikan, dengan sekitar 85,23% transaksi berstatus Selesai.

Jumlah transaksi mengalami fluktuasi antarbulan. Bulan dengan jumlah pesanan selesai tertinggi adalah Juli 2024, sedangkan nilai pembayaran tertinggi terjadi pada September 2024. Temuan tersebut menunjukkan bahwa volume transaksi dan nilai pembayaran tidak selalu bergerak secara identik.

Kategori Celengan menjadi kategori yang paling sering muncul dalam pesanan selesai, sedangkan Jawa Barat menjadi wilayah dengan kontribusi transaksi dan pembayaran terbesar.

Analisis pembatalan menunjukkan bahwa keputusan atau perubahan dari sisi pembeli merupakan salah satu sumber utama pembatalan. Sementara itu, analisis numerik menunjukkan distribusi pembayaran yang cenderung miring ke kanan dan terdapat hubungan positif yang cukup kuat antara berat pesanan dan nilai pembayaran.

Secara keseluruhan, hasil analisis menunjukkan bahwa data transaksi e-commerce dapat menghasilkan insight yang berguna untuk perencanaan stok, pengelolaan distribusi, pemantauan pembayaran, serta evaluasi pembatalan pesanan.

Namun, setiap hasil perlu diinterpretasikan sesuai dengan keterbatasan dataset dan tidak digunakan untuk menyimpulkan hubungan sebab-akibat tanpa analisis lanjutan.